

# 태양광 발전 기반 가로등 EMS의 AI 최적화 설계 및 성능 비교 분석

## AI Optimization Design and Performance Comparison Analysis of Solar-Powered Street Light EMS

박소현\*, 김가영\*, 박 건\*, 성연서\*, 이정호\*, 권기현\*

So-Hyun Park\*, Ga-Yeong Kim\*, Guhn Park\*, Yeon-Seo Seong\*, Jeong-Ho Lee\*, Ki-Hyeon Kwon\*

sh020712@naver.com

### 요 약

EMS는 현대 사회에서 높은 필요성을 가지는 시스템 중 하나이다. 사람이 직접 상황에 맞춰 에너지의 공급, 저장 및 다양한 작업들을 소화한다면 좋겠지만, 점차 많은 양과 다양한 종류의 에너지는 늘어만 가고, 섬세한 에너지 조절이 필요한 작업 공간에서는 실질적으로 사람이 제어하기 힘든 것이 현실이다. 특히 전기를 여러 방향으로 사용하는 도시환경 같은 경우, 모든 곳에 사람을 배치하여 전력 사용을 제어하는 것은 어찌보면 노동력 대비 효율이 굉장히 낮다고 볼 수 있다. 이러한 문제점들을 해결하기 위해 EMS들이 등장해왔다. 특히, 예측, 의사결정, 소통 등 다양한 방면에서 여러 알고리즘 모델들을 적용한 AI를 접목시켜 보다 고성능의 EMS로 발전해 나가고 있는 것이 추세이다. 우리는 이러한 여러 AI 알고리즘 모델들 중, 예측, 의사결정 분야에서 적합한 AI 알고리즘 모델의 성능을 비교 분석한다. 최종적으로 각각의 모델들의 고유한 장점과 단점과, 그것이 결과로서 어떻게 나오는지 확인하고 이유에 대해 고찰한다.

키워드 : EMS, 알고리즘, 데이터(Data), 전력, 저장, 공급, 예측

## I. 서 론

최근 기후 변화와 환경 문제에 대한 국제적인 관심이 증가함에 따라, 재생 가능 에너지의 효율적 관리와 활용이 전 세계적으로 중요한 이슈로 부상하고 있다. 이러한 이슈의 해결책으로, EMS는 에너지 관리의 중요한 핵심 요소로 자리 잡고 있다. 특히, AI 기술의 통합은 EMS의 성능을 극대화하여 예측 정확도를 높이고, 의사결정의 최적화를 가능하게 한다.

본 논문은 태양광 전력 생산량 예측 AI에 LSTM, XGBoost, Prophet, 및 GRU 모델을 적용하고 그 성능을 비교 분석한다. 이러한 모델들은 복잡한 시계열 데이터를 효과적으로 처리하여 태양광 패널의 전력 출력 변동성을 예측하는 데 각각 고유의 접근 방식과 장점을 제공하며, 그 결과를 확인한다. 또한, 전력의 저장과 공급 결정을 위한 AI에 Random Forest와 XGBoost 모델을 사용하여 각각의 성능을 비교 분석한다.

특히, 본 연구는 다양한 AI 모델의 성능을 종합적으로 비교

함으로써 예측 및 의사결정 AI에서의 정확성을 높이는 데 중점을 두고 있다. 이 연구는 모델들의 예측 성능 차이를 명확하게 규명하고, 각 모델의 특성과 효율성을 심도 있게 분석하여 실질적으로 활용 가능한 데이터를 제공한다. 이를 통해 AI 기반 EMS의 발전에 기여하며, 재생 가능 에너지의 보다 효율적인 관리와 활용을 도모하고자 한다.

## II. 설 계

### 2.1 EMS 체계 구성

서론에서 명시한 모델들의 성능 비교 및 분석을 진행한다. 예측 AI, 의사결정 AI, 총 2개의 AI를 제작하고, 각각의 AI를 학습시킨 후 모델 성능을 비교 및 분석한다. 알고리즘 모델들의 성능 분석을 위해, 예측 AI는 태양광 전력 생산량 예측 AI로, 의사결정 AI는 태양광 발전으로 생산된 전력 저장 및 공급 결정 AI로 제작한다. 태양광 전력 생산량 예측 AI에 위에서 언급한 4개 모델을 적용시키고 출력된 태양광 전력 생산량 예측 데이터의 정확도를 확인한다. 이후, 가장 정확도가 높은 알고리즘 모델의 태양광 전력 생산량 예측 데이터를 전력 저장 및 공급 결정 AI에서 사용한다. 전력 저장 및 공급

\* 강원대학교 전자정보통신공학과

결정 AI에서는 앞선 태양광 전력 생산량 예측 AI가 출력한 태양광 전력 생산량 예측 데이터와 시간별, 계절별, 생산되는 전력량, 저장된 전력량 등을 능동적으로 고려하여 도시의 가로등 점등 및 단기, 장기 배터리의 저장과 사용을 제어하도록 제작하고, 이를 2개 알고리즘 모델에 적용한 후 정확도를 확인한다. 이 두 AI를 사용하는 태양광 발전 가로등 EMS를 제작함으로써 모델들의 성능을 평가하는 것을 목표로 한다.

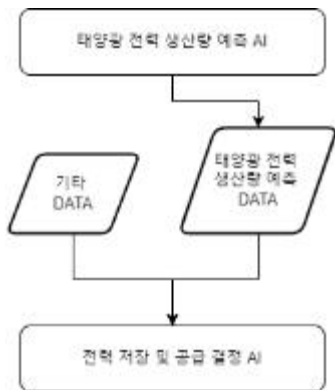


그림 1. 설계 기본틀

## 2.2 알고리즘 모델 개요

이 섹션(Section)에서는 실험에 사용되는 알고리즘 모델들에 대한 간략한 개요를 정리한다.

### 2.2.1 LSTM(Long Short-Term Memory) 모델

LSTM 모델은 시계열 데이터의 패턴과 상관관계를 학습하는 데 효과적인 순환 신경망(RNN)으로, RNN의 기울기 소실 문제를 해결하기 위해 개발된 LSTM은 셀 상태와 입력 게이트, 출력 게이트, 망각 게이트를 통해 정보의 흐름을 조절한다. 이로 인해 LSTM은 장기 의존성을 효과적으로 학습할 수 있어 시계열 데이터의 비선형성과 복잡한 상호작용을 잘 처리한다. LSTM을 활용한 시계열 예측 모델은 데이터 전처리, 모델 설계, 학습, 평가 및 예측의 절차를 거치며, 다양한 산업 분야에서 중요한 예측 도구로 사용되고 있다.[1]

### 2.2.2 XGBoost(eXtreme Gradient Boosting) 모델

XGBoost 모델은 Gradient Boosting 알고리즘을 기반으로 하며, 트리 기반의 앙상블 학습 방식을 채택하는데, 이는 시계열 데이터의 순차적인 패턴과 트렌드를 잘 파악하여 예측하는 데 유용하다. XGBoost의 각 트리는 이전 트리에서의 오차를 보정하여 시간에 따른 데이터의 변화를 잘 포착할 수 있다. 또한, Regularization을 통해 과적합을 방지하고 모델의

일반화 성능을 높일 수 있으며, XGBoost의 효율적인 병렬 처리 기능은 대규모 시계열 데이터 셋에서도 빠르게 학습할 수 있도록 한다. 따라서 XGBoost는 다양한 시계열 예측 및 분류 응용 분야에서 활용되고 있다.[2]

### 2.2.3 Prophet 모델

Prophet 모델은 Facebook에서 개발한 시계열 데이터 예측에 특화된 모델로, 특히 시계열 데이터의 분류 문제에 효과적이다. Prophet은 시간의 흐름에 따라 발생하는 다양한 패턴과 계절성을 고려하여 예측을 수행한다. 이 알고리즘은 주기적인 변동과 추세 등을 자동으로 감지하고 이를 예측에 반영한다. 또한, Prophet은 Bayesian 시계열 모델을 기반으로 하여 불확실성을 고려하여 예측 구간을 제공하므로, 안정적이고 신뢰할 수 있는 예측 결과를 제공한다. 이러한 특성 덕분에 Prophet은 비선형성과 복잡한 상호작용을 갖는 시계열 데이터를 효과적으로 처리하며, 특성 중요도를 제공하여 예측에 중요한 변수를 식별할 수 있다. 이러한 특성들을 바탕으로 Prophet은 다양한 시계열 데이터의 분류 문제에서 뛰어난 성능을 발휘한다.[3]

### 2.2.4 GRU(Gated Recurrent Unit) 모델

GRU 모델은 Recurrent Neural Network(RNN)의 변형 중 하나로, LSTM과 유사하지만 구조가 더 간단하여 계산 효율이 높다. GRU는 두 개의 게이트, 즉 업데이트 게이트와 리셋 게이트를 사용하여 정보의 흐름을 제어하고, 불필요한 정보를 걸러내며 중요한 정보를 장기간 보존할 수 있다. 이러한 구조 덕분에 GRU는 과거의 중요한 정보를 잃지 않고 유지할 수 있으며, 시간의 흐름에 따라 발생하는 다양한 패턴과 계절성을 효과적으로 반영할 수 있다. GRU는 LSTM과 비교하여 선형성과 복잡한 상호작용을 갖는 시계열 데이터를 효과적으로 처리하는 특징은 유사하지만, 구조가 단순하고 연산 비용이 적기 때문에 훈련 속도가 빠르다. 이러한 특성들 덕분에 GRU는 금융, 날씨 예측, 주가 예측, 자연어 처리 등 다양한 분야에서 시계열 데이터의 예측 및 분류 문제를 해결하는 데 강력한 도구로 사용되고 있다.[4]

### 2.2.5 RandomForest 모델

RandomForest 모델은 다수의 결정 트리(decision tree)를 결합하여 예측 성능을 향상시키는 앙상블 학습 방법으로, 시계열 데이터의 분류 문제에 효과적인 모델이다. 각 결정 트리는 데이터의 다른 부분을 학습하며, 최종 예측은 모든 트리의 예측을 다수결 방식으로 결정하는 형태로 이루어진다. 이 알

고리즘은 모델의 다양성을 높여 과적합을 방지하고, 안정적인 예측 결과를 제공한다. 특히, RandomForest는 시계열 데이터의 비선형성과 복잡한 상호작용을 잘 처리하며, 특성 중요도(feature importance)를 제공하여 어떤 변수가 예측에 중요한지 파악할 수 있다. 이러한 특성 덕분에 RandomForest는 다양한 시계열 데이터의 분류 문제에서 뛰어난 성능을 발휘한다.[5]

### 2.3 데이터 수집

어떤 식의 구조를 바탕으로 진행할 것인지를 정한다. 태양광 발전 가로등 EMS를 제작하기로 목표를 설정함에 따라, 어떤 식의 결과를 도출할 것인지에 관한 세부적인 사항들을 정하며, 전력의 저장과, 공급의 구조 등을 인위적으로 정한다. 아래의 표는 강원도 삼척 지자체의 답변을 바탕으로 설정된 실제 데이터들의 값이다.

표 1. 하드웨어 데이터 값

요소	값	설명
가로등 개수	8,400개	
단일 가로등 전력 소비량	150w	
통합 가로등 전력 소비량	대략 300,000kwh	보안등 포함

### 2.4 태양광 전력 생산량 예측 AI 데이터 구성

태양광 전력 생산량 예측 AI에는 대한민국 강원 소재의 K 대학교 건물의 (위도 : 37.4520433, 경도 : 129.1593049)의 2022년도, 2023년도 태양광 전력 생산 데이터를 사용한다. 또한 태양광 전력 생산량 예측을 보다 정확하게 파악할 수 있도록 기상청의 API를 불러와 동해시의 날씨 데이터를 접목시킨다.

표 2. 태양광 전력 생산량 예측 AI Data Column

구분	설명
date	공급되는 시간과 날짜. 1시간 단위. month, hour 등이 내포되어 있다. 예) 2022-01-01 12:00:00
Electricity Generation	date 기준, 생산되는 전력량
SOL_RAD_SLOPE	(빛 입사각에 따른) 일사량 데이터
TEMP	기상청 동해시 날씨 데이터에서의 온도
WS	기상청 동해시 날씨 데이터에서의 습도
HM	기상청 동해시 날씨 데이터에서의 풍속

아래의 그림 (2)와 그림 (3)은 태양광 전력 생산량 예측 AI에 사용된 데이터들의 통계를 그래프로 나타낸 것이다.




그림 2. 2022년도 태양광 전력 생산 데이터




그림 3. 2023년도 태양광 전력 생산 데이터

2022년도, 2023년도 태양광 전력 생산 데이터에서 발전량(AC\_W)를 확인해 보면, 중간에 발전량이 0인 부분이 있는데, 이 경우 실제 태양광 발전이 되지 않는 부조일수이거나, 태양광 패널의 전력 생산에 결함 등이 있어 측정되지 않은 값이다. 본 데이터들은 1시간 간격으로 구성되어 있으며 한 해 기준 8,760개의 데이터가 존재한다.

### 2.5 전력 저장 및 공급 결정 AI 데이터 구성

전력 저장 및 공급 결정 AI에는 실시간으로 생산되는 전력 값을 받고, Date 값과 앞의 태양광 전력 생산량 예측 AI에서 도출해낸 예상 전력 생산량, 가로등의 예상 전력 소비량을 고려하여, 가로등의 동작을 제어하도록 데이터를 아래와 같이 나눈다. 이후, 이상적인 학습데이터를 생성하여 알고리즘을 학습시킨다. 아래의 표 (3)는 전력 저장 및 공급 결정 AI에 사용된 데이터 칼럼(Data Column) 값들이다.

표 3. 전력 저장 및 공급 결정 AI Data Column

구분	설명
date	공급되는 시간과 날짜. 1시간 단위.
Electricity Generation	date 기준, 생산되는 전력량
Curr_Short_Battery	date 기준, 단기 배터리의 저장 전력 수치
Curr_Long_Battery	date 기준, 장기 배터리의 저장 전력 수치
Projected_Power_Production	태양광 전력 생산량 예측 AI가 예측한 전력 생산량
Season	date 기준, 계절 구분
Predicted_Power_Consumption	date 기준, 24시간 후의 전력 소비량
Select_Storage_Battery	단기 저장 배터리를 사용하여 전력을 공급
Select_Supply_Battery	장기 저장 배터리를 사용하여 전력을 공급
Light_Control	가로등의 점등 On, Off

또한, 태양광 패널에서 생산되는 전력을 보관하는 저장 매체로는 일반 리튬 이온 2차 전지와 수소 전지, 총 2개로 가정하였으며, 일반 리튬 이온 2차 전지를 단기, 수소 전지를 장기 전력 보관 배터리로 설정하였다. 단기, 장기 배터리는 각각의 효율이 다르며, EMS가 최대 효율성을 추구하여 능동적으로 전력을 저장하도록 학습데이터를 구성한다. 아래의 수식은 단기 배터리의 용량을 설정할 때 사용한 수식 (1)이다. 여기서 전력변환기의 효율은 고려하지 않았으며, 부조일수는 2022년도의 태양광 전력 생산 데이터의 부조일수 38일, 2023년도의 태양광 전력 생산 데이터의 부조일수 64일을 평균을 내고 대입하여 진행하였다.[6]

$$Batt_{Wh} = \frac{N_C \times E_L}{DOD \times \eta_B \times \eta_{con}} \quad - \text{수식 (1)}$$

$N_C$  : 부조일수,  $E_L$  : 부하의 연간 하루 평균 소비 전력량[Wh],  $DOD$  : 방전심도,  
 $\eta_B$  : 전지의 충·방전 효율,  $\eta_{con}$  : 전력변환기 효율

또한, 장기 배터리는 용량의 한계 없이 저장이 가능한 수소 전지로 가정하고 진행한다. 저장 및 공급 효율은 아래의 표와 같이 설정하였다[7][8][9].

아래의 표 (4)와 표 (5)는 학습데이터를 제작할 시 정해진 모든 요소들에 대한 최종 설정값과 그에 대한 설명이다.

표 4. 학습데이터 요소 설정값 및 설명 1

요소	설정값	설명
단기 배터리 용량	9,916.67(kwh)	2022, 2023년도 부조일수 평균값을 대입. 전력변환기 효율은 고려하지 않음.
장기 배터리 용량	100,000(kwh)	수소 전지로 가정
단기 배터리 초기 전력 보유 수치	2975.9995(kwh)	단기 배터리 용량의 30%
장기 배터리 초기 전력 보유 수치	200000	수소 전지로 가정
가로등 소비 전력(1개)	0.15(kwh)	
가로등 개수	700(개)	
단기 배터리 저장 효율	90%	전력 손실율 10%
장기 배터리 저장 효율	65.8%	전력 손실율 34.2%
단기 배터리 공급 효율	99.7%	전력 손실율 0.3%
장기 배터리 공급 효율	60%	전력 손실율 40%
계절별 가로등 동작 시간(겨울)	17:00 ~ 07:00	총 14시간 동작
계절별 가로등 동작 시간(봄)	18:00 ~ 06:00	총 12시간 동작
계절별 가로등 동작 시간(여름)	20:00 ~ 05:00	총 9시간 동작
계절별 가로등 동작 시간(가을)	18:00 ~ 06:00	총 12시간 동작

표 5. 학습데이터 요소 설정값 및 설명 2

계절	최소 단기 배터리 용량 리미트	최대 단기 배터리 용량 리미트	리미트 해제 시 용량
겨울	30%	80%	90%
봄	0.25%	75%	85%
여름	0.2%	70%	80%
가을	0.25%	75%	85%

위 표 (4)와 표 (5)의 학습데이터 요소들을 반영하여, AI가 동작하도록 학습데이터를 구성하고 학습시킨다. 아래의 그림들은 AI가 궁극적으로 학습되어야 하는 이상향을 다이어그램으로 나타내었다.




그림 4. 이상적인 Season 다이어그램

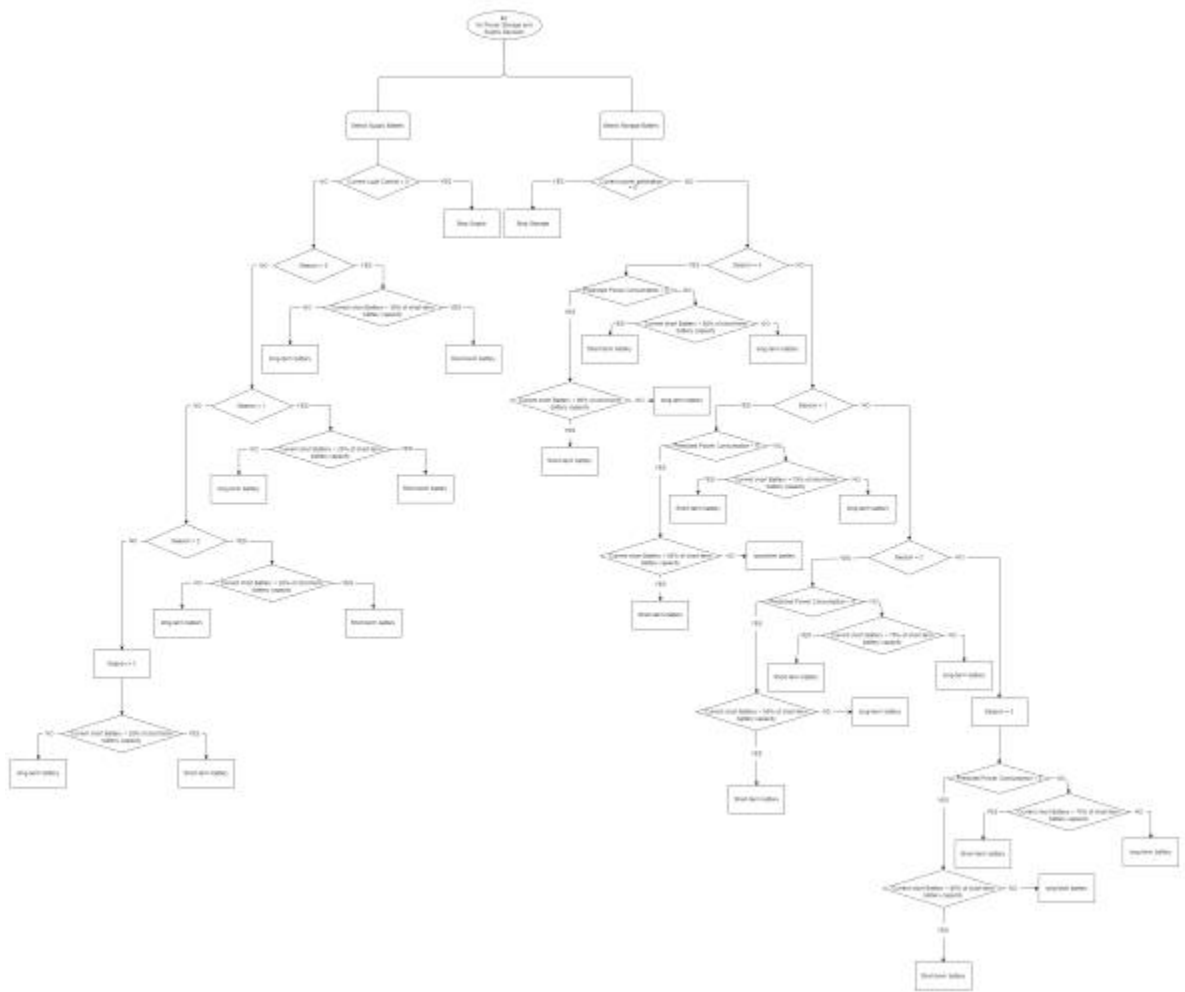


그림 5. 이상적인 전력 저장 및 공급 종합 다이어그램

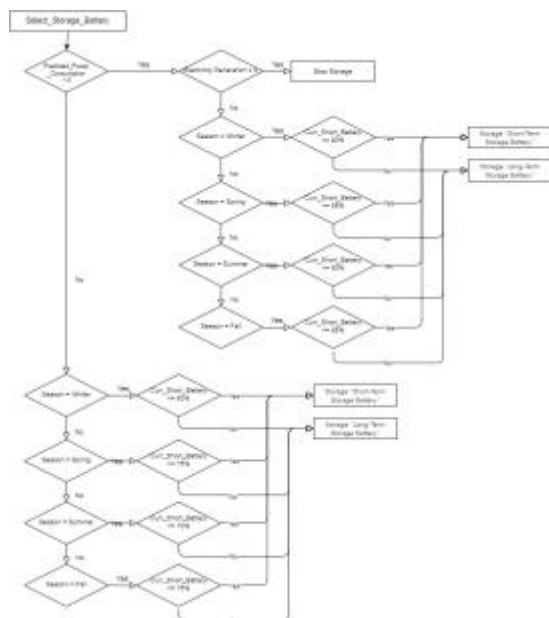


그림 6. 이상적인 Select\_Storage\_Battery 다이어그램

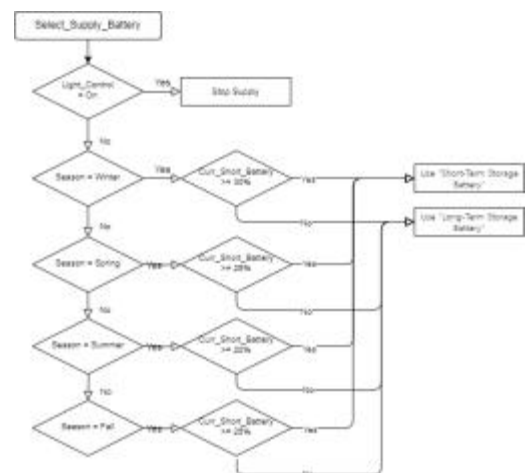


그림 7. 이상적인 Select\_Supply\_Battery 다이어그램

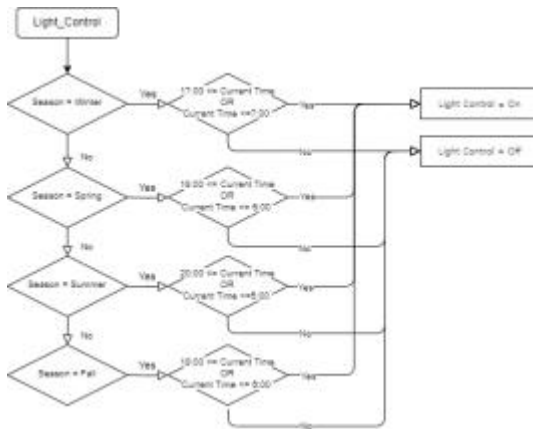


그림 8. 이상적인 Light\_Control 다이어그램

### Ⅲ. 실험 및 검토

#### 3.1 알고리즘 모델 평가 방법

알고리즘 모델 평가는 각 모델별로 적용된 AI를 5회씩 동작시키고 정확도( $R^2$ )와 예측 시간을 평균을 내어 성능을 평가한다. 이때,  $R^2$ 는 결정 계수(Coefficient of Determination)으로 종속 변수의 분산 중 모델을 통해 설명 가능한 비율을 나타낸다.

$R^2$ 는 다음과 같은 수식 (2)으로 계산된다.

$$R^2 = 1 - \frac{SS_{res}}{SS_{tot}} \quad \text{-- 수식 (2)}$$

여기서  $SS_{res}$ 는 잔차 제곱 합(Residual sum of squares)이고,  $SS_{tot}$ 는 총 제곱 합(Total sum of squares)이다. 잔차 제곱 합은 실제 값과 모델 예측 값의 차이를 제곱한 값들의 합이며, 총 제곱 합은 실제 값과 실제 값의 평균의 차이를 제곱한 값들의 합이다.

$R^2 = 1$ 일 경우, 모델이 데이터를 완벽하게 예측한다는 의미이며,  $R^2 = 0$ 일 경우, 모델이 데이터의 분산을 전혀 설명하지 못하고, 평균으로 예측하는 것과 같음을 의미한다.

$R^2 < 0$ 일 경우, 모델이 성능이 평균을 기반으로 한 예측보다도 더 나쁘다는 것을 의미하며, 이는 모델이 데이터를 설명하기는커녕 오히려 혼란을 더하는 경우임을 나타낸다.

다시 말해,  $R^2$  값이 1에 가까워질수록 정확도가 더 높은

알고리즘 모델임을 말한다.

#### 3.2 태양광 전력 생산량 예측 AI 알고리즘 모델 평가

태양광 전력 생산량 예측 AI 알고리즘 모델들을 평가하기 위해, 대한민국 강원 소재의 K 대학교 2022년도 태양광 전력 생산 데이터를 LSTM, XGBoost, Prophet, GRU 각각의 알고리즘에게 학습시킨다. 이후, 2023년도 태양광 전력 생산량 예측을 시행시키고, 실제 2023년도 태양광 전력 생산량과의 비교를 통해 정확도를 확인한다. 각 알고리즘 모델들마다 총 5회씩의 예측을 진행하여, 예측 속도, 정확도( $R^2$ )를 기준으로 알고리즘의 성능을 평가한다.

아래의 표 (6)은 5회씩 태양광 전력 생산량 예측 AI 알고리즘 모델들의 예측 시행하였을 때의 소요된 시간과 정확도( $R^2$ )이다.

표 6. 각 모델별 예측 정확도와 소요 시간

시행 횟수	LSTM		XGBoost	
	정확도 ( $R^2$ )	소요 시간 (sec)	정확도 ( $R^2$ )	소요 시간 (sec)
1회	0.90	94.45	0.88	0.54
2회	0.90	98.14	0.88	0.66
3회	0.91	150.95	0.88	0.53
4회	0.90	148.93	0.88	0.58
5회	0.90	149.15	0.88	0.55
평균	0.902	128.324	0.88	0.572
시행 횟수	Prophet		GRU	
	정확도 ( $R^2$ )	소요 시간 (sec)	정확도 ( $R^2$ )	소요 시간 (sec)
1회	0.84	127.86	0.90	151.45
2회	0.84	129.33	0.90	148.41
3회	0.84	131.18	0.89	149.23
4회	0.84	131.94	0.90	101.03
5회	0.84	130.74	0.89	90.52
평균	0.84	130.21	0.896	128.128

5회 예측 결과, 정확도 측면에서는 LSTM, GRU, XGBoost, Prophet 순으로 높은 결과를 보여줬다. 소요 시간 측면에서는 XGBoost가 평균 0.572[sec]라는 결과로 알고리즘 모델들 중 가장 빨랐으며, 뒤를 이어 GRU, LSTM, Prophet 순으로 소요 시간이 짧았음을 확인할 수 있었다. 정확도( $R^2$ ) 측면에서는 각 알고리즘 모델 끼리의 최대 차이가 0.062로 큰 차이가 없었으나, 소요 시간에서는 최대 차이가 129.638[sec]로 매우 큰 차이를 확인할 수 있었다.

#### 3.3 전력 저장 및 공급 결정 AI 알고리즘 모델 평가

전력 저장 및 공급 결정 AI의 알고리즘 모델들을 평가하기 위해, Random Forest, XGBoost 알고리즘 모델을 인위적으로

제작한 학습데이터로 학습을 진행한다. 이후, 총 5회씩의 예측을 진행하여, 인위적으로 만든 2023년도 의사결정 데이터 원본과 알고리즘이 출력한 전력 저장 및 공급 결정 데이터를 통해 알고리즘 모델 각각의 성능을 비교한다.

학습하기 위한 변수와 목표하는 타겟(Target) 변수의 설정은 아래의 표 (7)와 같이 설정하고 값을 비교한다.

표 7. 학습 변수 및 목표 변수 설정

구분	변수
학습 변수	Electricity Generation
	month
	hour
	Curr_Short_Battery
	Projected_Power_Production
목표 변수	Season
	Predicted_Power_Consumption
	Select_Storage_Battery
	Select_Supply_Battery
	Light_Control

아래의 표 (8)은 5회씩 전력 저장 및 공급 결정 AI 알고리즘 모델들의 예측 시행하였을 때의 소요된 시간과 목표 변수 값들에 대한 정확도( $R^2$ )이다.

표 8. Random Forest 목표 변수 예측 정확도 및 소요 시간

Random Forest 정확도 ( $R^2$ )						
변수명	1회	2회	3회	4회	5회	평균
Season	1	1	1	1	1	1
Predicted_Power_Consumption	0.9952	0.9952	0.9952	0.9952	0.9952	0.9952
Select_Storage_Battery	0.9985	0.9985	0.9985	0.9985	0.9985	0.9985
Select_Supply_Battery	0.9894	0.9894	0.9894	0.9894	0.9894	0.9894
Light_Control	0.9979	0.9979	0.9979	0.9979	0.9979	0.9979
Random Forest 소요 시간 (sec)						
구분	1회	2회	3회	4회	5회	평균
소요 시간	4.71	3.42	3.44	4.37	3.42	3.872

표 9. XGBoost 목표 변수 예측 정확도 및 소요 시간

XGBoost 정확도 ( $R^2$ )						
변수명	1회	2회	3회	4회	5회	평균
Season	1	1	1	1	1	1
Predicted_Power_Consumption	0.9965	0.9965	0.9965	0.9965	0.9965	0.9965
Select_Storage_Battery	0.9959	0.9959	0.9959	0.9959	0.9959	0.9959
Select_Supply_Battery	0.9852	0.9852	0.9852	0.9852	0.9852	0.9852
Light_Control	0.9983	0.9983	0.9983	0.9983	0.9983	0.9983
XGBoost 소요 시간 (sec)						
구분	1회	2회	3회	4회	5회	평균
소요 시간	1.12	1.18	3.95	1.13	1.13	1.702

예측 5회 진행 결과, Random Forest, XGBoost 모델 모두 정확도 측면에서 큰 차이 없이 높은 정확도를 보였음을 확인할 수 있다. 특히 ‘Season’ 변수의 경우 한 치의 오차도 없이 두 알고리즘 모델 모두 데이터를 정확히 예측하였으며, ‘Season’ 변수를 포함한 총 목표 변수 5개를  $R^2 = 0.98$  이상의 수치로 예측하였음을 확인하였다.

다만, 소요 시간에서는 차이가 남음을 확인할 수 있는데, Random Forest의 경우 평균 3.872[sec]의 시간이 소요되었으나, XGBoost는 평균 1.702[sec]의 시간으로 Random Forest 모델보다 2.17[sec] 빠른 예측 속도를 보여주었다.

‘Season’ 변수에 따라 일정하게 작동하는 가로등을 기준으로 전력 저장 및 공급 모델을 만들었기 때문에 AI 모델이 내놓는 값이 실제로는 다른 값인 경우는 드물다. 또한, 목표 변수가 연속 값이 아니고, 0과 1로 딱 떨어지는 결괏값을 예측하기 때문에 전력 저장 및 공급 결정 AI 알고리즘 모델들의 정확도가 높은 것으로 추정할 수 있다.

## IV. 결 론

결과적으로, 태양광 발전 가로등 EMS를 제작하고, 각 알고리즘 모델들로 예측을 진행하여 성능을 평가하였다. 대체적으로 데이터 예측 정확도는 높은 편이었으며, LSTM, GRU, Prophet, XGBoost, Random Forest 모델을 모두 적용된 AI에서 높은 정확도 수치를 기록하였다. 소요 시간 측면에서는 큰 차이를 확인할 수 있었는데, XGBoost가 태양광 전력 생산량 예측 AI, 전력 저장 및 공급 결정 AI에서 모두 큰 차이를 보이며, 압도적인 예측 속도를 보여주었다.

## 참 고 문 헌

본 연구를 통해, 높은 정확도와 빠른 계산을 요구하는 EMS 프로그램에서는 XGBoost가 가장 적합하게 동작할 것으로 판단할 수 있었다. 다만, 학습데이터의 빠대였던 대한민국 강원 소재의 K 대학교 2022, 2023년도 태양광 전력 생산 데이터에서 태양광 모듈 오류로 인한 부조일수가 상대적으로 높아 알고리즘 모델들이 학습을 진행할 때, 잘못된 학습을 진행하였을 가능성이 존재하며, 전력 저장 및 공급 결정 AI에서 비교한 알고리즘 모델들의 수가 적어 아쉬운 점을 확인할 수 있다.

각 알고리즘 모델의 정확도 향상 및 소요 시간 단축을 위해 다양한 방안을 고려할 필요가 있다. 우선, 학습 데이터의 정확성을 높이기 위해 외부 태양광 전력 생산 API를 활용하는 방안이 제안될 수 있다. 이러한 접근은 예측 모델의 신뢰성을 강화하는 데 기여할 것이다. 또한, 알고리즘의 소요 시간을 줄이기 위한 몇 가지 전략이 제시될 수 있다. 예를 들어, 데이터 전처리 과정을 최적화하거나 병렬 처리를 통해 계산 속도를 향상시키는 방법이 있다. 아울러, 경량화된 모델을 사용하거나 하드웨어 가속 기술을 도입함으로써 알고리즘의 효율성을 극대화할 수 있다. 이러한 접근법들은 XGBoost와 같은 모델의 처리 속도를 더욱 향상시키는 데 기여할 것이다.

본 논문의 연구는 실용적 측면에서 몇 가지 중요한 적용 가능성을 제시한다. 첫째, 다양한 AI 모델의 성능을 비교 분석한 결과는 향후 EMS 개발자들이 최적의 알고리즘을 선택하는 데 중요한 참고 자료가 될 수 있다. 둘째, XGBoost의 빠른 예측 속도는 실시간 데이터 처리가 중요한 분야에서 매우 유용하게 활용될 수 있을 것으로 사료된다. 예를 들어, 스마트 시티의 에너지 관리 시스템이나 실시간 전력 배분 시스템 등에서 XGBoost는 효율적인 솔루션을 제공할 수 있을 것이다. 마지막으로, 본 연구에서 제시된 분석 방법론은 다른 재생 가능 에너지 관리 시스템에도 적용될 수 있어, 다양한 환경과 조건에서 최적의 알고리즘을 찾는 데 기여할 수 있다.

이와 같은 연구의 실용적 적용 가능성은 단순한 이론적 연구를 넘어 실제 현장에서의 활용성을 높이며, 지속 가능한 에너지 관리를 위한 중요한 기초 자료로써 사용될 수 있을 것으로 기대된다. AI 기반 EMS 제작 및 구현에 있어, 본 논문의 결과가 유용한 기초 비교 분석 자료로써 활용되길 바란다.

- [1] Hochreiter, Sepp, and Jurgen Schmidhuber. "Long Short-Term Memory." *Neural Computation*, vol. 9, no. 8, 1997, pp. 1735-1780.
- [2] Chen, Tianqi, and Carlos Guestrin. "XGBoost: A Scalable Tree Boosting System." *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016.
- [3] Taylor, Sean J., and Benjamin Letham. "Forecasting at Scale." *The American Statistician*, vol. 72, no. 1, 2018, pp. 37-45.
- [4] Cho, Kyunghyun, et al. "Learning Phrase Representations Using RNN Encoder-Decoder for Statistical Machine Translation." *arXiv preprint*, arXiv:1406.1078, 2014.
- [5] Svetnik, Vladimir, et al. "Random Forest: A Classification and Regression Tool for Compound Classification and QSAR Modeling." *Journal of Chemical Information and Computer Sciences*, vol. 43, no. 6, 2003, pp. 1947-1958.
- [6] 김기영, 최우진. "독립형 태양광 발전 시스템의 무정전 전력공급을 위한 시스템 용량 최적 선정에 관한 연구." *전력전자학회 논문지*, vol. 23, no. 2, 2018, pp. 77-85.
- [7] Pedram, M., N. Chang, Y. Kim, and Y. Wang. "Hybrid Electrical Energy Storage Systems." *2010 ACM/IEEE International Symposium on Low-Power Electronics and Design (ISLPED)*, Austin, TX, 2010, pp. 363-368.
- [8] 한국에너지기술연구원. "2050 탄소중립 달성을 위한 수소에너지 역할 분석." *KIER 기술분석 Report*, vol. 2, no. 1, 2021, p. 45.
- [9] Deloitte Insights. "2050 탄소중립 로드맵." *Deloitte Insights*, no. 19, 2021, p. 126.